

# 파이썬 기초 프로그래밍과 응용

250221 - 5일차

# 강화 학습 (Reinforcement Learning)

- 상태(State)
  - 에이전트가 현재 처한 상황을 나타내는 정보의 집합
  - 에이전트가 의사결정을 내릴 때 사용하는 환경에 대한 관찰 정보
- 행동(Action)
  - 에이전트가 특정 상태에서 선택할 수 있는 가능한 모든 행위
  - 에이전트의 행동 선택에 따라 환경이 변화하고 새로운 상태로 이동
- 보상(Reward)
  - 에이전트가 특정 행동을 취한 후 환경으로부터 받는 피드백
  - 행동의 좋고 나쁨을 수치화한 평가 지표

# Q-러닝 알고리즘 이해

1. Q-테이블
2. Q-값(Q-value)
3. 벨만 방정식(Bellman Equation)

## Q-러닝 알고리즘


| 상태 | 행동 1 | 행동 2 | 행동 3 |
|----|------|------|------|
| S1 | 0.5  | 0.2  | -0.1 |
| S2 | 0.0  | 0.8  | 0.3  |
| S3 | -0.3 | 0.7  | 0.5  |

# Deep Q-Network (DQN)

- 신경망 기반 Q-Learning의 작동 방식

# 퍼셉트론(Perceptron)


- 생물학적 뉴런의 기능을 모방
- 다수의 입력 신호를 받아 하나의 출력 신호를 생성



# 활성 함수 (Activation Function)


Traditional  
Non-Linear  
Activation  
Functions

Sigmoid



$$y = 1 / (1 + e^{-x})$$


Hyperbolic Tangent



$$y = (e^x - e^{-x}) / (e^x + e^{-x})$$


Modern  
Non-Linear  
Activation  
Functions

Rectified Linear Unit  
(ReLU)



$$y = \max(0, x)$$


Leaky ReLU



$$y = \max(\alpha x, x)$$

$\alpha$  = small const. (e.g. 0.1)


Exponential LU



$$y = \begin{cases} x, & x \geq 0 \\ \alpha(e^x - 1), & x < 0 \end{cases}$$

# 인공신경망(Artificial Neural Network)

- 다층 퍼셉트론(Multi-Layer Perceptron)
- 인간의 두뇌 구조를 모방
- 입력층, 숨겨진 층, 출력층
- 비선형 관계를 모델링
- 층이 4개 이상이 되면 딥러닝







# 역전파(Backpropagation)

- 출력이 목표 출력과 얼마나 다른지를 오차를 계산
- 오차를 출력에서 입력쪽으로 역으로 전파하여 가중치를 조정
- 경사 하강법(Gradient Descent)
  - 신경망의 손실 함수(Loss Function)를 최소화


## 경사 하강법(Gradient Descent)



# 경사 하강법(Gradient Descent)



# 역전파(Backpropagation)



| X1 | X2 | Y |
|----|----|---|
| 0  | 0  | 0 |
| 0  | 1  | 0 |
| 1  | 0  | 0 |
| 1  | 1  | 1 |

Other Initial Values

$W1$ : 0.7

$W2$ : 0.3

Theta: 0.5

Learning rate: 0.2

| x1 | x2 | $X1*w1$ | $X2*w2$ | Sum | Theta | Y | Expected Y | Same? |
|----|----|---------|---------|-----|-------|---|------------|-------|
| 0  | 0  | 0       | 0       | 0   | 0.5   | 0 | 0          | Yes   |
| 0  | 1  | 0       | 0.3     | 0.3 | 0.5   | 0 | 0          | Yes   |
| 1  | 0  | 0.7     | 0       | 0.7 | 0.5   | 1 | 0          | No    |

## 역전파(Backpropagation)

Error: (Expected Y) - Y  $\rightarrow 0 - 1 = -1$

Delta: Learning rate\*Error  $\rightarrow -1*0.2 = -0.2$

W1\_delta = w1\*delta, W2\_delta = w2\*delta

New\_W1:  $0.7 - 0.2 = 0.5$ , New\_W2: 0.3

Other Initial Values

W1: 0.7


W2: 0.3

Theta: 0.5

Learning rate: 0.2

| x1 | x2 | X1*w1 | X2*w2 | Sum | Theta | Y | Expected Y | Same? |
|----|----|-------|-------|-----|-------|---|------------|-------|
| 0  | 0  | 0     | 0     | 0   | 0.5   | 0 | 0          | Yes   |
| 0  | 1  | 0     | 0.3   | 0.3 | 0.5   | 0 | 0          | Yes   |
| 1  | 0  | 0.7   | 0     | 0.7 | 0.5   | 1 | 0          | No    |

# 역전파(Backpropagation)



| X1 | X2 | Y |
|----|----|---|
| 0  | 0  | 0 |
| 0  | 1  | 0 |
| 1  | 0  | 0 |
| 1  | 1  | 1 |

Other Initial Values

$W1$ : 0.5


$W2$ : 0.3

Theta: 0.5


Learning rate: 0.2

| x1 | x2 | $X1*w1$ | $X2*w2$ | Sum | Theta | Y | Expected Y | Same? |
|----|----|---------|---------|-----|-------|---|------------|-------|
| 0  | 0  | 0       | 0       | 0   | 0.5   | 0 | 0          | Yes   |
| 0  | 1  | 0       | 0.3     | 0.3 | 0.5   | 0 | 0          | Yes   |
| 1  | 0  | 0.5     | 0       | 0.5 | 0.5   | 0 | 0          | Yes   |
| 1  | 1  | 0.5     | 0.3     | 0.8 | 0.5   | 1 | 1          | Yes   |

## 역전파(Backpropagation)



## 역전파(Backpropagation)







# 의사결정 나무(Decision Tree)

- 트리 구조
- 종속 변수 - 독립 변수 간의 관계를 탐색
- 데이터를 기준에 따라 분할
- 각 분할이 가능한 한 순수해질 때까지 분기
- ‘순수’는 각 분할이 하나의 클래스에 속하는 데이터를 최대한 포함하는 상태

# 의사결정 나무(Decision Tree)



## 랜덤 포레스트 (Random Forest)



# 랜덤 포레스트 (Random Forest)

- 여러 개의 의사결정 나무(Decision Tree)를 사용하여 예측을 수행
- 앙상블(ensemble) 학습법
- 각 의사결정 나무는 랜덤하게 선택된 데이터 샘플로 학습
- 최종 예측은 각 나무의 결과를 다수결 결정
- 모델의 해석이 상대적으로 어려움

# 모델 성능 평가 지표들

- 정확도 (Accuracy): 전체 예측 중에서 올바르게 예측한 비율
- 정밀도 (Precision): 모델이 양성으로 예측한 것 중 실제로 양성인 비율.
- 재현율 (Recall): 실제 양성인 샘플 중에서 모델이 양성으로 올바르게 예측한 비율
- F1-점수 (F1 Score):  
정밀도와 재현율의 조화 평균. 두 지표 간의 균형을 평가.  
데이터셋 클래스 불균형이 있는 상황에서 유용.

## 모델 성능 평가 지표들



- Type 1 Error: 병에 걸리지 않은 사람을 병에 걸렸다고 오진
- Type 2 Error: 병에 걸린 사람을 병에 걸리지 않았다고 오진

|                                   | Actual -- True/False        |                            |
|-----------------------------------|-----------------------------|----------------------------|
|                                   | True                        | False                      |
| Predicted --<br>Positive/Negative | True Positive               | False Positive<br>(Type I) |
|                                   | False Negative<br>(Type II) | True Negative              |

# 모델 성능 평가 지표들

|                                                                                            |                    | predicted condition                                                                                             |                                                                                                   |                                                                                                                                             |                                                                                                                 |
|--------------------------------------------------------------------------------------------|--------------------|-----------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| total population                                                                           |                    | prediction positive                                                                                             | prediction negative                                                                               | Prevalence = $\frac{\Sigma \text{condition positive}}{\Sigma \text{total population}}$                                                      |                                                                                                                 |
| true condition                                                                             | condition positive | True Positive (TP)                                                                                              | False Negative (FN)<br>(type II error)                                                            | True Positive Rate (TPR), Sensitivity,<br>Recall, Probability of Detection<br>$= \frac{\Sigma \text{TP}}{\Sigma \text{condition positive}}$ | False Negative Rate (FNR),<br>Miss Rate<br>$= \frac{\Sigma \text{FN}}{\Sigma \text{condition positive}}$        |
|                                                                                            | condition negative | False Positive (FP)<br>(Type I error)                                                                           | True Negative (TN)                                                                                | False Positive Rate (FPR), Fall-out,<br>Probability of False Alarm<br>$= \frac{\Sigma \text{FP}}{\Sigma \text{condition negative}}$         | True Negative Rate (TNR),<br>Specificity (SPC)<br>$= \frac{\Sigma \text{TN}}{\Sigma \text{condition negative}}$ |
| Accuracy<br>$= \frac{\Sigma \text{TP} + \Sigma \text{TN}}{\Sigma \text{total population}}$ |                    | Positive Predictive Value (PPV),<br>Precision<br>$= \frac{\Sigma \text{TP}}{\Sigma \text{prediction positive}}$ | False Omission Rate (FOR)<br>$= \frac{\Sigma \text{FN}}{\Sigma \text{prediction negative}}$       | Positive Likelihood Ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$                                                                           | Diagnostic Odds Ratio (DOR)<br>$= \frac{\text{LR+}}{\text{LR-}}$                                                |
|                                                                                            |                    | False Discovery Rate (FDR)<br>$= \frac{\Sigma \text{FP}}{\Sigma \text{prediction positive}}$                    | Negative Predictive Value (NPV)<br>$= \frac{\Sigma \text{TN}}{\Sigma \text{prediction negative}}$ | Negative Likelihood Ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$                                                                           |                                                                                                                 |

# 인공신경망의 시각화







# 인공신경망의 시각화 자료

[https://adamharley.com/nn\\_vis/mlp/2d.html](https://adamharley.com/nn_vis/mlp/2d.html)

- MNIST (필기 숫자 인식) 학습에 대한 시각화:

# 신경망(Neural Network)


- Universal Approximation Capability (범용 근사능)
  - 은닉층이 하나 있는 신경망은 충분한 뉴런이 있으면 모든 연속함수를 근사할 수 있다



# 신경망(Neural Network)

- Universal Approximation Capability (범용 근사능)
  - 은닉층이 하나 있는 신경망은 충분한 뉴런이 있으면 모든 연속함수를 근사할 수 있다

<http://playground.tensorflow.org>



# Deep Q-Network (DQN) vs Q-러닝

- 보상 표현 방식

- Q-러닝은 Q-테이블을 사용하여 모든 상태-행동 쌍의 가치(보상)을 저장
- Q-테이블은 일종의 함수
  - 입력: (현재 상태, 현재 행동), 출력: 보상(Q-Value)
- DQN은 신경망을 사용하여 Q-함수를 근사화하여 가치를 추정


- 메모리와 확장성

- Q-러닝은 상태와 행동이 많아지면 테이블이 커짐
  - 연속적인 상태, 행동에 대해서는 처리 불가능
- DQN은 신경망을 통해 함수를 근사화하므로 연속적이거나 아주 큰 상태/행동 공간 처리 가능

# 강화 학습 - 알파고


## 알파고의 정책망과 가치망 구조

정책망



입력된 기보를 바탕으로  
특정 상황에 전문가들이 많이 두는  
수로 탐색의 폭을 좁혀주는 것

가치망



걸러진 수 가운데 현재 대국  
상황에서 승산이 높은 수를 예측.  
형세를 판단해주는 것

# Deep Q-Network (DQN)

- 신경망 기반 Q-Learning의 작동 방식
  - 경험 리플레이 (Experience Replay)
  - 타겟 네트워크 (Target Network)

# Deep Q-Network (DQN)

- 경험 리플레이(Experience Replay)
  - 이전 경험을 저장하고 샘플링하여 학습에 사용하는 기법
  - 학습 안정성 향상
    - 샘플링을 통해 데이터 분포를 평탄화하여 손실함수(예측값과 실제값의 차이 평가함수)의 변동성 감소
  - 데이터 효율성 증대
    - 동일한 데이터를 여러 번 학습에 활용할 수 있어 데이터 필요량 감소

# Deep Q-Network (DQN)

- 타깃 네트워크(Target Network)

- Q-네트워크를 2개 운용하여 하나는 학습하는데 사용하고, 다른 하나는 행동을 예측하는데 사용
  - 다른 하나의 행동예측을 위한 네트워크가 타깃 네트워크
- 학습 안정성 향상
  - 행동 예측 부분에 대한 학습 반영을 0.001배 이하로 설정하여 학습 중의 예측의 변동성 감소
- 수렴 특성 개선
  - 메인 네트워크가 안정적인 기준값에 따라 더 효과적으로 학습합니다.



# Deep Q-Network (DQN)

1. 환경에서 상태 관찰
2. 행동 선택 ( $\epsilon$ -greedy 정책에 의해 탐험과 경험 활용의 분배)
3. 보상 획득 및 다음 상태 저장
4. 경험 재플레이에 의한 신경망 업데이트
5. 타깃 네트워크 주기적 업데이트

# Stable Baselines3


- OpenAI Gym과 PyTorch를 기반
- Scikit-Learn과 비슷하게 강화학습 알고리즘 모음
- 강화학습을 쉽게 적용하고 테스트 가능.

# Deep Q-Network (DQN)

Q-Learning으로는 할 수 없는 연속적인 Gym 에 대한 예시

- Cartpole Gym
- Highway\_Env

# LSTM (Long Short-Term Memory)



# 최신 AI 트렌드

- 생성형 AI (Diffusion)
  - 노이즈의 추가와 제거로 패턴을 학습하고 생성에 이용
- LLM (Large Language Model, 대형 언어 모델)
  - 트랜스포머: 학습된 데이터 간의 관계를 얻어내는 방법론

# 자기 주의 메커니즘 (Self-Attention Mechanism)

## Attention Visualizations






Figure 3: An example of the attention mechanism following long-distance dependencies in the encoder self-attention in layer 5 of 6. Many of the attention heads attend to a distant dependency of the verb 'making', completing the phrase 'making...more difficult'. Attentions here shown only for the word 'making'. Different colors represent different heads. Best viewed in color.

# 생성형 AI (Diffusion)



# 생성형 AI (Diffusion)





# 머신러닝 추천 강의

## 인프런 - 나도코딩 파이썬 무료강의 활용편7 머신러닝

- 파이썬 문법, 알고리즘 보다 머신러닝 원리, 실제 예제를 통한 실무 위주 강의

## AWS - Basics of Machine Learning

- 아마존 AWS 에서 제공하는 머신러닝 강의
- AWS 제품 사용을 익히면서 머신러닝 학습

# 머신러닝 추천 강의

## 네이버 부스트 코스 - Andrew Ng 교수님 딥러닝 코스

- 네이버 아이디 필요, 한글 자막, 자료 제공



딥러닝 1단계: 신경망과 딥러닝

Andrew Ng | 부스트코스

♥ 1251    👤 11054    📺 기본

무료강의



딥러닝 2단계: 심층 신경망 성능 향상시키기

Andrew Ng | 부스트코스

♥ 244    👤 3576    📺 기본

무료강의



딥러닝 3단계: 머신러닝 프로젝트 구조화하기

Andrew Ng | 부스트코스

♥ 69    👤 3329    📺 기본

무료강의



딥러닝 4단계: 합성곱 신경망 네트워크 (CNN)

Andrew Ng | 부스트코스

♥ 283    👤 4319    📺 기본

무료강의

# 머신러닝 추천 강의

## [Great Learning - Python for Machine Learning](#)

- Numpy, Pandas, Matplot 등 머신러닝 데이터 다루기, 시각화 기초부터 시작하는 강의

## [coursera - Python의 응용 머신러닝, University of Michigan](#)

감사합니다